

Processamento Digital de Imagens

Sinais Aleatórios

Eduardo A. B. da Silva

Programa de Engenharia Elétrica - COPPE/UFRJ

Laboratório de Sinais, Multimídia e Telecomunicações
eduardo@smt.ufrj.br

Sergio L. Netto

Programa de Engenharia Elétrica - COPPE/UFRJ

Laboratório de Sinais, Multimídia e Telecomunicações
sergioln@smt.ufrj.br

Abril de 2017



Sumário





① Sinais Aleatórios

- Campos Aleatórios Discretos
- Função Densidade Espectral
- Resultados da Teoria da Estimação
- Alguns Resultados da Teoria da Informação





Sinais Aleatórios

- Na maioria das aplicações, não conhecemos a priori o sinal que vamos processar.
 - Por exemplo, em transmissão, se o sinal for conhecido a priori, não é necessário transmiti-lo.
- Nestes casos, para projetar um sistema, precisamos conhecer as propriedades da classe de sinais em que estamos interessados como um todo.
- Uma boa maneira de fazer isto é usar a estatística.
- Usar a estatística significa saber a probabilidade de ocorrência de cada sinal em particular.
- Um sinal aleatório pode ser definido como uma sequência de variáveis aleatórias $u(n)$.
 - Variável aleatória: função que associa um número a um evento.

- Por exemplo, uma imagem pode ter pixels variando entre 0 e 255, de 1 em 1.
 - Se ela tiver dimensões pequenas, como, por exemplo, 256×256 , ela vai ter $256^2 = 65536$ pixels.
 - Como cada pixel pode ter 256 valores diferentes, pode haver $256^{65536} \approx 10^{157826}$ imagens diferentes.
- Para estimar a probabilidade de cada imagem 256×256 teríamos que observar imagens de modo a preencher um histograma com aproximadamente 10^{157826} que é um número com 157826 zeros.
 - Considerando que estima-se que o universo tenha apenas aproximadamente 10^{80} partículas elementares, esta tarefa é impraticável sob quaisquer aspectos!
- Neste caso, temos que fazer medidas mais simples do que achar a probabilidade de cada sinal possível. As mais intuitivas são:
 - **Média:** $\mu_u(n) \triangleq \mu(n) = E[u(n)]$ (cada n pode ter uma média diferente)
 - **Variância:** $\sigma_u(n) = \sigma(n) = E[|u(n) - \mu(n)|^2]$
- Entretanto, a média e a variância muitas vezes não dão informação completa sobre a dinâmica de um conjunto de sinais.



$$\mu = 0 \quad \sigma^2 = 5 \quad \forall t$$



$$\mu = 0 \quad \sigma^2 = 5 \quad \forall t$$

- Notamos que os conjuntos de sinais da esquerda e da direita possuem características claramente diferentes, mas ambos têm média zero e variância 5, para qualquer instante de tempo.
- Outras medidas são necessárias nestes casos, as mais intuitivas sendo:

- **Covariância:**

$$\text{cov}[u(n), u(n')] = r_{uu}(n, n') = r(n, n') = E[(u(n) - \mu_u(n))(u^*(n') - \mu_u^*(n'))]$$

- **Covariância cruzada:**

$$\text{cov}[u(n), v(n')] = r_{uv}(n, n') = E[(u(n) - \mu_u(n))(v^*(n') - \mu_v^*(n'))]$$

- **Autocorrelação:** $a_{uu}[n, n'] = a(n, n') = E[u(n)u^*(n')] = r(n, n') + \mu_u(n)\mu_u^*(n')$

- **Correlação cruzada:** $a_{uv}[n, n'] = E[u(n)v^*(n')] = r_{uv}(n, n') + \mu_u(n)\mu_v^*(n')$

- Para um vetor \mathbf{u} , $N \times 1$, definimos:

- $E[\mathbf{u}] = \boldsymbol{\mu} = \{\mu(n)\}$, vetor $N \times 1$

- $\text{cov}[\mathbf{u}] = E[(\mathbf{u} - \boldsymbol{\mu})(\mathbf{u}^* - \boldsymbol{\mu}^*)^T] \triangleq \mathbf{R}_u \triangleq \mathbf{R} = \{r(n, n')\}$, matriz $N \times N$

- $\text{cov}[\mathbf{u}, \mathbf{v}] = E[(\mathbf{u} - \boldsymbol{\mu}_u)(\mathbf{v}^* - \boldsymbol{\mu}_v^*)^T] \triangleq \mathbf{R}_{uv} \triangleq \mathbf{R} = \{r_{uv}(n, n')\}$, $N \times N$

- **Função densidade de probabilidade:** $p_u(u)$ tal que $P[x \leq u \leq x + dx] = p_u(x)dx$

- **Gaussiana:**

$$p_u(u) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(u-\mu)^2}{2\sigma^2}}$$

- **Laplaciana:**

$$p_u(u) = \frac{1}{\sqrt{2}\sigma} e^{-\frac{|u-\mu|\sqrt{2}}{\sigma}}$$

- **Processos Gaussianos:**

$$p_u(\mathbf{u}) = p_u(u_1, u_2, \dots, u_N) = \frac{1}{(2\pi)^{\frac{N}{2}} |\mathbf{R}|^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{u}-\boldsymbol{\mu})^{*t} \mathbf{R}^{-1}(\mathbf{u}-\boldsymbol{\mu})}$$

\Rightarrow Qualquer subsequência é gaussiana.

- **Processos estacionários.**

⇒ No **sentido estrito**: $u(n)$ tal que a densidade conjunta de qualquer subsequência é a mesma da sequência deslocada, ou seja, $\{u(l), 1 \leq l \leq k\}$ possui a mesma p.d.f. que $\{u(l+m), 1 \leq l \leq k\}, \forall m, \forall k$.

⇒ No **sentido amplo**:
$$\begin{cases} E[u(n)] = \text{constante} \\ E[u(n)u^*(n')] = r(n - n') \end{cases}$$

sentido amplo \rightarrow sentido estrito, **mas**

sentido estrito \rightarrow sentido amplo **só para processos gaussianos**

$$r(n) = \text{cov}[u(n), u(0)] = \text{cov}[u(n+n'), u(n')], \forall n', n.$$

$$\begin{cases} r(n, n') = r^*(n', n) \\ \sum_n \sum_n x(n)r(n, n')x^*(n') \geq 0, \quad x(n) \neq 0, \forall n \end{cases}$$

- **Processo de Markov:**

$$P[u(n) | \underbrace{u(n-1), u(n-2), \dots}_{\text{todo o passado}}] =$$

$$P[u(n) | \underbrace{u(n-1), u(n-2), \dots, u(n-p)}_{p \text{ amostras passadas}}] \quad (\text{Markov de ordem } p)$$

- **Exemplo:** Processo estacionário de markov de primeira ordem
 $r(n) = \rho^{|n|}$, $|\rho| < 1$, $\forall n$ (bom modelo para linhas de imagens)

$$R = \begin{bmatrix} 1 & \rho & \rho^2 & \dots & \rho^{N-1} \\ \rho & 1 & \rho & \dots & \rho^{N-2} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \rho^{N-1} & \rho^{N-2} & \dots & \rho & 1 \end{bmatrix} \Rightarrow (\text{toepliz})$$

- **Ortogonalidade e Independência**

Independência: $p_{x,y}(x, y) = p_x(x)p_y(y)$

Ortogonalidade: $E[xy^*] = 0$

Descorrelação: $E[xy^*] = E[x]E[y^*]$, ou $E[(x - \mu_x)(y - \mu_y)^*] = 0$

Campos Aleatórios Discretos

- **Imagens:** Enorme número de variáveis aleatórias ($512 \times 512 = 262.144$ v.a.)
 - ⇒ Não é praticável medir ou especificar densidades conjuntas.
 - ⇒ Especificar somente 1º e 2º momentos (médias e covariâncias).
- $E[u(m, n)] = \mu(m, n)$
- $\text{cov}[u(m, n), u(m', n')] = E[(u(m, n) - \mu(m, n))(u^*(m', n') - \mu^*(m', n'))] = r(m, n; m', n')$
- Caso estacionário (sentido amplo):
$$\begin{cases} \mu(m, n) = \mu = \text{constante} \\ r(m, n; m', n') = r(m - m'; n - n') \end{cases}$$
- Abuso de notação: $r(m, n) = \text{cov}[u(m, n), u(0, 0)] = \text{cov}[u(m + m', n + n'), u(m', n')]$

- O campo aleatório $x(m, n)$ é ruído branco se quaisquer dois elementos diferentes $x(m, n)$ e $x(m', n')$ são descorrelatados: $r_x(m, n; m', n') = \sigma_x^2(m, n)\delta(m - m', n - n')$
- Um campo aleatório é Gaussiano se qualquer segmento do campo definido numa malha finita é gaussiano.

- **Simetria e não-negatividade:** $r(m, n; m', n') = r(m', n'; m, n)$

$$\sum_m \sum_{m'} \sum_n \sum_{n'} x(m, n) r(m, n; m', n') x^*(m', n') \geq 0, \quad x(m, n) \geq 0, \forall m, n$$

- **Covariâncias separáveis e isotrópicas**

$$\begin{array}{ll} \text{Separável:} & r(m, n; m', n') = r_1(m, m') r_2(n, n') \quad \text{não-estacionário} \\ & r(m, n) = r_1(m) r_2(n) \quad \text{estacionário} \end{array}$$

Modelo separável muito usado em processamento de imagens:

$$\begin{cases} r(m, n) = \sigma^2 \rho_1^{|m|} \rho_2^{|n|} & |\rho_1| < 1, \quad |\rho_2| < 1 \\ \sigma^2 : \text{variância do campo aleatório} \\ \rho_1 = \frac{r(1, 0)}{\sigma^2} & \rho_2 = \frac{r(0, 1)}{\sigma^2} \end{cases}$$

Modelo mais realista (mas menos tratável) para muitas imagens (isotrópico, não-separável):

$$\begin{cases} r(m, n) = \sigma^2 e^{-\sqrt{\alpha_1 m^2 + \alpha_2 n^2}} & \alpha_1 = -\ln \rho_1, \quad \alpha_2 = -\ln \rho_2 \\ \alpha_1 = \alpha_2 = \alpha \Rightarrow r(m, n) = \sigma^2 \rho^d & d = \sqrt{m^2 + n^2}, \quad \rho = e^{-|\alpha|} \end{cases}$$

\Rightarrow para muitas imagens, $\rho_1, \rho_2 \simeq 0.95$

Função Densidade Espectral

$$S_u(z) \triangleq S(z) = \sum_{n=-\infty}^{\infty} r_u(n)z^{-n}$$

Densidade espectral de potência:
$$\begin{cases} S_u(\omega) = S_u(z) \Big|_{z=e^{j\omega}} = \sum_{n=-\infty}^{\infty} r_u(n)e^{-j\omega n} \\ r_u(n) = \frac{1}{2\pi} \int_{-\pi}^{\pi} S_u(\omega)e^{j\omega n} d\omega \end{cases}$$

2 dimensões:

$$\begin{cases} S_u(z_1, z_2) \triangleq S(z_1, z_2) \triangleq \sum_{m=-\infty}^{\infty} \sum_{n=-\infty}^{\infty} r_u(m, n)z_1^{-m}z_2^{-n} \\ S_u(\omega_1, \omega_2) \triangleq S_u(z_1, z_2) \Big|_{z_1=e^{j\omega_1}, z_2=e^{j\omega_2}} = \sum_{m=-\infty}^{\infty} \sum_{n=-\infty}^{\infty} r_u(m, n)e^{-j\omega_1 m}e^{-j\omega_2 n} \\ r_u(m, n) = \frac{1}{4\pi^2} \int_{-\pi}^{\pi} \int_{-\pi}^{\pi} S_u(\omega_1, \omega_2)e^{j\omega_1 n + j\omega_2 m} d\omega_1 d\omega_2 \end{cases}$$

$$\Rightarrow \sigma_u^2 = E[|u(m, n) - \mu|^2] = r_u(0, 0) = \frac{1}{4\pi^2} \int_{-\pi}^{\pi} \int_{-\pi}^{\pi} S_u(\omega_1, \omega_2) d\omega_1 d\omega_2$$

- $S(\omega_1, \omega_2) = S^*(\omega_1, \omega_2)$ (pois $r(m, n) = r^*(-m, -n)$)
- $S(\omega_1, \omega_2) \geq 0, \quad \forall \omega_1, \omega_2$
- $x(m, n) \longrightarrow \boxed{H(\omega_1, \omega_2)} \longrightarrow y(m, n) \quad S_y(\omega_1, \omega_2) = |H(\omega_1, \omega_2)|^2 S_x(\omega_1, \omega_2)$

• **Exemplo 1:**


$$r(m, n) = \sigma^2 \delta(m, n) \text{ (ruído branco)}$$

$$S(\omega_1, \omega_2) = \sigma^2$$

- Exemplo 2:

$$r(m, n) = \sigma^2 \rho_1^{|m|} \rho_2^{|n|}$$

$$S(\omega_1, \omega_2) = \frac{\sigma^2(1 - \rho_1^2)(1 - \rho_2^2)}{(1 + \rho_1^2 - 2\rho_1 \cos \omega_1)(1 + \rho_2^2 - 2\rho_2 \cos \omega_2)} = S_1(\omega_1)S_2(\omega_2)$$



- Resultados da Teoria da Estimação:**

$\{y(n), 1 \leq n \leq N\} \Rightarrow$ observações

$x \Rightarrow$ variável aleatória que se quer estimar.

$\Rightarrow \hat{x}$ tal que $\sigma_\varepsilon^2 = E[(x - \hat{x})^2]$ é mínimo.

$$\Rightarrow \hat{x} = E[x|\mathbf{y}] \triangleq E[x|y(1), y(2), \dots, y(N)] = \int_{-\infty}^{\infty} \varepsilon p_{x|y}(\varepsilon) d\varepsilon$$

$$E[\hat{x}] = E[E(x|\mathbf{y})] = E[x]$$

- Princípio da ortogonalidade:**

$\forall g(\mathbf{y})$, se \hat{x} é o estimador ótimo (MSE), então $E[(x - \hat{x})g(\mathbf{y})] = 0$.

Prova:

$$E[\hat{x}g(\mathbf{y})] = E[E(x|\mathbf{y})g(\mathbf{y})] = E[E(xg(\mathbf{y}))|\mathbf{y}]] = E[xg(\mathbf{y})]$$

$$\Rightarrow \begin{cases} E[(x - \hat{x})\hat{x}] = 0 \\ E[(x - \hat{x})g(\hat{x})] = 0 \end{cases} \quad \text{pois } \hat{x} \text{ também é uma função de } \mathbf{y}$$

- **Melhor estimador linear:**

$$\hat{x} = \sum_{n=1}^N \alpha(n)y(n)$$

$\alpha(k)$ tal que $E[(x - \hat{x})^2]$ é minimizado

$$\Rightarrow \sum_{k=1}^N \alpha(k)E[y(k)y(n)] = E[xy(n)] \Rightarrow \mathbf{R}_y \boldsymbol{\alpha} = \mathbf{r}_{xy}$$

$$\Rightarrow \boldsymbol{\alpha} = \mathbf{R}_y^{-1} \mathbf{r}_{xy}$$

$$\mathbf{r}_{xy} : N \times 1$$

$$\boldsymbol{\alpha} : N \times 1$$

$$\mathbf{R}_y : N \times N$$

$$\sigma_\varepsilon = \sigma_x^2 = \boldsymbol{\alpha}^T \mathbf{r}_{xy} \Rightarrow \text{erro mínimo}$$

\Rightarrow Exato para variáveis gaussianas de média zero, melhor estimativa baseada no MSE para variáveis não-gaussianas.


$$\text{Média} \neq 0 \Rightarrow \hat{x} - \mu_x = \sum_{n=1}^N \alpha(n)[y(n) - \mu_y(n)]$$

\Rightarrow Mesmo resultado, só que \mathbf{R}_y e \mathbf{r}_{xy} são matrizes de covariância e covariância cruzada.

Alguns Resultados da Teoria da Informação

- **Informação:** $I_k = -\log_2 p_k$ (bits) (p_k é a probabilidade do símbolo k , isto é, $\sum_{k=1}^L p_k = 1$)
- **Entropia:** Informação média $H = -\sum_{k=1}^L p_k \log_2 p_k$ (bits/mensagem)
 L símbolos: entropia máxima $= -\sum_{k=1}^L \frac{1}{L} \log_2 \frac{1}{L} = \log_2 L$ bits.
- **Shannon:** Fonte com entropia H
Codifica-se sem distorção com $H + \varepsilon$ bits, $\varepsilon \rightarrow 0$
Codifica-se com H bits, e distorção $\rightarrow 0$

- **Ex:** 2 símbolos $H = -p \log p - (1 - p) \log(1 - p)$



- **“Rate-Distortion Function”**

⇒ Conversão A/D: quanto mais bits, menos distorção.

⇒ $R_D(x)$: menor número de bits necessário para atingir uma distorção D .

⇒ x reproduzido com valor y : $D = E[(x - y)^2]$

Para variáveis gaussianas:

$$R_D = \begin{cases} \frac{1}{2} \log_2 \left(\frac{\sigma^2}{D} \right), & D \leq \sigma^2 \\ 0, & D > \sigma^2 \end{cases} \quad (1)$$

$$= \max \left[0, \frac{1}{2} \log_2 \left(\frac{\sigma^2}{D} \right) \right] \quad (2)$$

“Justificativa grosseira”: sinal com $\begin{cases} \text{energia} = \sigma^2 \Rightarrow \text{“amplitude” } \sigma \\ \text{distorção } D \Rightarrow \text{“amplitude” do erro } \sqrt{D} \end{cases}$

Intervalo entre passos de quantização $\sqrt{D} \Rightarrow$ número de níveis $= \frac{\sigma}{\sqrt{D}}$

$$\Rightarrow 2^{R_D} = \frac{\sigma}{\sqrt{D}} \Rightarrow R_D = \frac{1}{2} \log_2 \frac{\sigma}{\sqrt{D}}$$

se $\sigma^2 < D$, $R_D = 0$ (não preciso transmitir nada)

- Sejam $\{x(0), x(1), \dots, x(N-1)\}$, v.a. gaussianas, codificadas independentemente, e $\{y(0), y(1), \dots, y(N-1)\}$ seus valores reproduzidos. Então:

$$D = \frac{1}{N} \sum_{k=0}^{N-1} E [(x(k) - y(k))^2]$$

$$\begin{cases} R_D = \frac{1}{N} \sum_{k=0}^{N-1} \max \left[0, \frac{1}{2} \log_2 \frac{\sigma_k^2}{\theta} \right] \\ D = \frac{1}{N} \sum_{k=0}^{N-1} \min [0, \sigma_k^2] \end{cases}$$

Resolução do sistema de equações

