

# *Processamento Digital de Imagens*

## Restauração de Imagens

**Eduardo A. B. da Silva**

**Programa de Engenharia Elétrica - COPPE/UFRJ**

Laboratório de Sinais, Multimídia e Telecomunicações  
eduardo@smt.ufrj.br

**Sergio L. Netto**

**Programa de Engenharia Elétrica - COPPE/UFRJ**

Laboratório de Sinais, Multimídia e Telecomunicações  
sergioln@smt.ufrj.br

Abril de 2017



# Sumário

- ① Restauração de Imagens
  - Restauração de Imagens
  - Filtragem Inversa
  - Filtragem de Wiener

# Restauração de Imagens

⇒ Recuperação de degradações na imagem causadas pelo “ambiente” de aquisição de imagem:

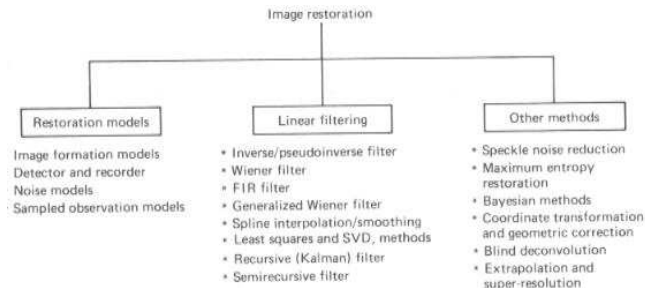
- Ruído de sensores;
- Embaçamento devido à falta de foco da câmera;
- Movimento relativo entre câmera e objeto;
- Turbulência atmosférica aleatória;
- Etc....

⇒ Sua validade depende da acurácia com que se conhece o processo de degradação e do processo do projeto de filtros.

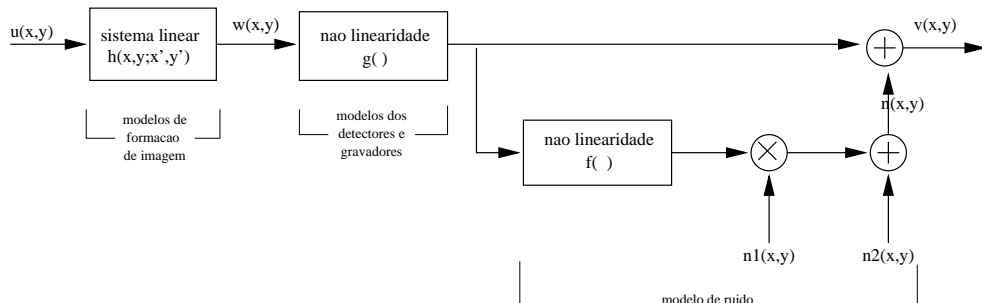
⇒ A medida de fidelidade utilizada é, usualmente, o erro médio quadrático (MSE). Se usa às vezes os critérios de máxima entropia e “weighted” MSE.

⇒ Qual a diferença para “Image Enhancement”?


- “Enhancement” envolve mais o realce ou extração de características da imagem do que restauração de degradações;
- Problemas de restauração de imagens podem ser quantificados precisamente, enquanto critérios de realce são difíceis de representar matematicamente;
- Técnicas de restauração de imagens frequentemente dependem das propriedades de uma classe ou conjunto de dados, enquanto as técnicas de realce dependem muito mais de cada imagem.




## Modelos de Observação de Imagens



⇒ Tipicamente:



Restauração:



# Modelos de Formação de Imagens

Exemplo: Motion Blur  $\Rightarrow$  movimento no eixo  $x$  com velocidade  $\vartheta$ .

$$v(x, y) = \frac{1}{T} \int_0^T v(x - \vartheta t, y) dt, \quad \alpha = \vartheta t$$

$$v(x, y) = \frac{1}{T} \int_0^{\vartheta T} v(x - \alpha, y) \frac{d\alpha}{\vartheta}$$

$$\text{Seja } P_a(\alpha) = \begin{cases} \frac{1}{a}, & 0 \leq \alpha \leq a \\ 0, & \text{n.d.p.} \end{cases}$$


$$v(x, y) = \int_{-\infty}^{\infty} P_{\vartheta T}(\alpha) v(x - \alpha, y) d\alpha = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} P_{\vartheta T}(\alpha) \delta(\beta) v(x - \alpha, y - \beta) d\alpha d\beta$$

$\Rightarrow$  Equivale a filtrar com um filtro com resposta ao impulso  $h(x, y) = P_{\vartheta T}(x) \delta(y)$  (sinc na frequência);

Para movimento linear uniforme em direções arbitrárias, temos (na frequência):

$$H(m, n) = \frac{T}{\pi(\alpha m + \beta n)} \sin(\pi(\alpha m + \beta n)) e^{-j\pi(\alpha m + \beta n)}$$

## Exemplo: Turbulência atmosférica



$$H(u, v) = e^{-k(u^2 + v^2)^{5/6}}$$



# Outros Modelos de Formação de Imagens

**TABLE 8.1** Examples of Spatially Invariant Models

Type of system	Impulse response $h(x, y)$	Frequency response $H(\xi_1, \xi_2)$
Diffraction limited, coherent (with rectangular aperture)	$ab \operatorname{sinc}(ax) \operatorname{sinc}(by)$	$\operatorname{rect}\left(\frac{\xi_1}{a}, \frac{\xi_2}{b}\right)$
Diffraction limited, incoherent (with rectangular aperture)	$\operatorname{sinc}^2(ax) \operatorname{sinc}^2(by)$	$\operatorname{tri}\left(\frac{\xi_1}{a}, \frac{\xi_2}{b}\right)$
Horizontal motion	$\frac{1}{\alpha_0} \operatorname{rect}\left(\frac{x}{\alpha_0} - \frac{1}{2}\right) \delta(y)$	$e^{-j\pi\xi_1\alpha_0} \operatorname{sinc}(\xi_1\alpha_0)$
Atmospheric turbulence	$\exp\{-\pi\alpha^2(x^2 + y^2)\}$	$\frac{1}{\alpha^2} \exp\left[-\frac{\pi(\xi_1^2 + \xi_2^2)}{\alpha^2}\right]$
Rectangular scanning aperture	$\operatorname{rect}\left(\frac{x}{\alpha}, \frac{y}{\beta}\right)$	$\alpha\beta \operatorname{sinc}(\alpha\xi_1) \operatorname{sinc}(\beta\xi_2)$
CCD interactions	$\sum_{k,l=-1}^1 \alpha_{k,l} \delta(x - k\Delta, y - l\Delta)$	$\sum_{k,l=-1}^1 \alpha_{k,l} e^{-j2\pi\Delta(\xi_1 k + \xi_2 l)}$

## Exemplos:

Imagem original

Imagem borrada por  $\text{sinc}^2$  fracoImagem borrada por  $\text{sinc}^2$  forte

Imagem borrada por movimento horizontal



# Modelos de Detectores e Gravadores

Para filmes fotográficos, scanners e displays, a resposta a uma entrada  $w$  é geralmente não-linear:

$$g = \alpha w^\beta$$

Ex: Para filmes, um modelo mais acurado é  $d = \gamma \log_{10} \omega - d_0$

$\omega$  : intensidade de luz incidente;

$d$  : densidade ótica;

$\gamma$  : intensidade de luz incidente;

Luz refletida ou transmitida  $g = 10^{-d}$

# Modelos de Ruído

Ruído aparece tipicamente durante a aquisição de imagens e/ou transmissão; ;

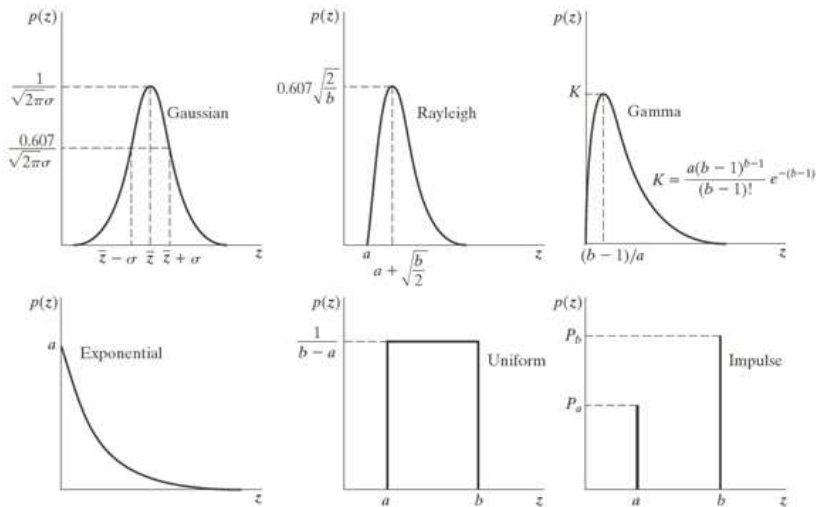
Ex: ruído num feixe de elétrons:  $\eta(x, y) = \underbrace{\sqrt{g(x, y)}\eta_1(x, y)}_{\text{emissão aleatória de elétrons}} + \underbrace{\eta_2(x, y)}_{\text{ruído térmico}}$

Podemos assumir (simplificadamente) que:

- O ruído é **independente** das coordenadas espaciais;
- **Não há correlação** entre os valores dos pixels e os valores do ruído (não é verdade para ruído periódico);


# Principais modelos de ruído:

Name	PDF	Mean and Variance	CDF
<b>Uniform</b>	$p_z(z) = \begin{cases} \frac{1}{b-a} & \text{if } a \leq z \leq b \\ 0 & \text{otherwise} \end{cases}$	$m = \frac{a+b}{2}, \quad \sigma^2 = \frac{(b-a)^2}{12}$	$F_z(z) = \begin{cases} 0 & z < a \\ \frac{z-a}{b-a} & a \leq z \leq b \\ 1 & z > b \end{cases}$
<b>Gaussian</b>	$p_z(z) = \frac{1}{\sqrt{2\pi}b} e^{-(z-a)^2/2b^2}$ $-\infty < z < \infty$	$m = a, \quad \sigma^2 = b^2$	$F_z(z) = \int_{-\infty}^z p_z(v) dv$
<b>Salt &amp; Pepper</b>	$p_z(z) = \begin{cases} P_a & \text{for } z = a \\ P_b & \text{for } z = b \\ 0 & \text{otherwise} \end{cases}$ $b > a$	$m = aP_a + bP_b$ $\sigma^2 = (a-m)^2P_a + (b-m)^2P_b$	$F_z(z) = \begin{cases} 0 & \text{for } z < a \\ P_a & \text{for } a \leq z < b \\ P_a + P_b & \text{for } b \leq z \end{cases}$
<b>Lognormal</b>	$p_z(z) = \frac{1}{\sqrt{2\pi}bz} e^{-[\ln(z)-a]^2/2b^2}$ $z > 0$	$m = e^{a+(b^2/2)}, \quad \sigma^2 = [e^{b^2} - 1]e^{2a+b^2}$	$F_z(z) = \int_0^z p_z(v) dv$
<b>Rayleigh</b>	$p_z(z) = \begin{cases} \frac{2}{b}(z-a)e^{-(z-a)^2/b} & z \geq a \\ 0 & z < a \end{cases}$	$m = a + \sqrt{\pi b/4}, \quad \sigma^2 = \frac{b(4-\pi)}{4}$	$F_z(z) = \begin{cases} 1 - e^{-(z-a)^2/b} & z \geq a \\ 0 & z < a \end{cases}$
<b>Exponential</b>	$p_z(z) = \begin{cases} ae^{-az} & z \geq 0 \\ 0 & z < 0 \end{cases}$	$m = \frac{1}{a}, \quad \sigma^2 = \frac{1}{a^2}$	$F_z(z) = \begin{cases} 1 - e^{-az} & z \geq 0 \\ 0 & z < 0 \end{cases}$




Diferentes modelos de ruído podem surgir devido à efeitos de ruído térmico, de circuitos eletrônicos, em *range imaging*, imageamento por laser, erro de chaveamento de circuitos ou registradores, etc..

Exemplo: considere a seguinte imagem:



- ⇒ Qual a aparência de seu histograma?
- ⇒ Adicione ruído com diferentes distribuições.




Gaussian

Rayleigh

Gamma





Exponential

Uniform

Salt & Pepper

## Estimação de modelos de ruído

⇒ Dada uma imagem, como posso estimar o modelo do ruído?






## Ruído periódico


Surge devido à interferência elétrica ou eletromecânica durante aquisição.



## Restauração de Ruído Periódico

⇒ Operamos no domínio da frequência.






Filtros:



From left to right, perspective plots of ideal, Butterworth (of order 1), and Gaussian bandreject


Filtros:



# Filtragem Inversa

## Filtro Inverso

Considere nosso modelo típico de distorção:



Na ausência de ruído ( $\eta(x, y) = 0$ ), temos:

$$V(\omega_1, \omega_2) = H(\omega_1, \omega_2)U(\omega_1, \omega_2)$$

Uma solução para corrigir as distorções introduzidas pelo sistema  $H(\omega_1, \omega_2)$  é então utilizar um filtro de restauração inverso:



$$H'(\omega_1, \omega_2) = \frac{1}{H(\omega_1, \omega_2)}$$




Assim:



$$\begin{aligned}\hat{U}(\omega_1, \omega_2) &= H^l(\omega_1, \omega_2)V(\omega_1, \omega_2) \\ &= \frac{1}{H(\omega_1, \omega_2)}H(\omega_1, \omega_2)U(\omega_1, \omega_2) \\ &= F(\omega_1, \omega_2)\end{aligned}$$

⇒ Problema: o projeto de filtros inversos é difícil porque eles são usualmente instáveis ( $H^l(\omega_1, \omega_2)$  não existe se  $H(\omega_1, \omega_2) = 0$ );





perda de informação

 A dashed blue arrow pointing from the original image towards the blurred image, indicating the loss of information during the blurring process.


Na presença de ruído, nosso modelo é:


$$V(\omega_1, \omega_2) = H(\omega_1, \omega_2)U(\omega_1, \omega_2) + N(\omega_1, \omega_2)$$

Utilizando o filtro inverso:


$$\hat{U}(\omega_1, \omega_2) = V(\omega_1, \omega_2)H'(\omega_1, \omega_2) = U(\omega_1, \omega_2) + \frac{N(\omega_1, \omega_2)}{H(\omega_1, \omega_2)}$$

⇒ Se  $H(\omega_1, \omega_2)$  é pequeno, amplifico (muito) o ruído;

Ex:

Guassain Noise (zero mean,  $\sigma = 1$ )

Restored Image



## Filtro Pseudo-Inverso

Uma solução é fazer:

$$H^{-}(\omega_1, \omega_2) = \begin{cases} \frac{1}{H(\omega_1, \omega_2)}, & H(\omega_1, \omega_2) \neq 0 \\ 0, & H(\omega_1, \omega_2) = 0 \end{cases}$$

Na prática, considero  $H(\omega_1, \omega_2) < \varepsilon$

$$\text{Seja } V(\omega_1, \omega_2) = H(\omega_1, \omega_2)U(\omega_1, \omega_2) \Rightarrow \hat{U}(\omega_1, \omega_2) = \frac{V(\omega_1, \omega_2)}{H(\omega_1, \omega_2)}$$

$$\text{Se adiciono ruído} \Rightarrow \hat{U}(\omega_1, \omega_2) = \frac{V(\omega_1, \omega_2)}{H(\omega_1, \omega_2)} + \frac{N(\omega_1, \omega_2)}{H(\omega_1, \omega_2)}$$

$\Rightarrow$  Ainda assim, se  $H(\omega_1, \omega_2)$  é muito pequeno, mesmo uma pequena quantidade de ruído pode ser muito amplificada.

$\Rightarrow$  Posso aumentar  $\varepsilon$ , piorando o desempenho do filtro;

Ex: Na ausência de ruído:

Imagem original



Imagem borrada



Imagem recuperada pelo filtro inverso




Imagem recuperada pelo filtro pseudo-inverso



Ex: Na presença de ruído:

Imagem borrada e com ruído



Imagem restaurada pelo filtro pseudo-inverso





# Filtragem de Wiener

⇒ Usada para restaurar imagens na presença de embaçamento e ruído.

⇒ Olha a imagem e o ruído como dois processos estocásticos:

$v(m, n)$  é uma observação do processo  $u(m, n)$ ,  $E[u(m, n)] = E[v(m, n)] = 0$ .

Nosso problema é: a partir da observação de  $v(m, n)$ , qual a estimativa  $\hat{u}(m, n)$  de  $u(m, n)$  que minimiza o erro médio quadrático

$$\sigma_e^2 = E[|u(m, n) - \hat{u}(m, n)|^2]$$

A estimativa que minimiza o erro é dada por:

$$\hat{u}(m, n) = \underbrace{E[u(m, n) | v(k, l)]}_{\text{difícil de calcular (preciso de } p_{u|v})}, \forall k, l.$$

Uma solução é trabalhar com a melhor estimativa linear para  $\hat{u}(m, n)$ :

$\Rightarrow$  Assumo que  $\hat{u}(m, n)$  é do tipo  $\sum_k \sum_l g(m, n; k, l) v(k, l)$

$\Rightarrow$  Acho  $g(m, n; k, l)$  tal que  $\sigma_e^2$  é mínimo.

Assumindo que os procesos  $u(m, n)$  e  $v(m, n)$  são gaussianos, do princípio da ortogonalidade temos que:

$$E\{[(u(m, n) - \hat{u}(m, n))]v(m', n')\} = 0, \quad \forall m, n, m', n'$$

(o erro de estimação é ortogonal à estimativa)

$$\Rightarrow \sum_k \sum_l g(m, n; k, l) r_{vv}(k, l; m', n') = r_{uv}(m, n; m', n')$$

Equação de Wiener

Se  $u$  e  $v$  são conjuntamente estacionários:  $r_{uv}(m, n; m', n') = r_{uv}(m - m', n - n')$

$$\Rightarrow \sum_k \sum_l g(m - k, n - l) r_{vv}(k, l) = r_{uv}(m, n)$$

Calculando a transformada de Fourier:

$$G(\omega_1, \omega_2) S_{vv}(\omega_1, \omega_2) = S_{uv}(\omega_1, \omega_2) \Rightarrow G(\omega_1, \omega_2) = S_{uv}(\omega_1, \omega_2) S_{vv}^{-1}(\omega_1, \omega_2)$$

Temos ainda que:

$$\hat{u}(m, n) = \sum_k \sum_l g(m - k, n - l) v(k, l) \Rightarrow \hat{U}(\omega_1, \omega_2) = G(\omega_1, \omega_2) V(\omega_1, \omega_2)$$

Supondo o sistema linear com ruído aditivo:

$$v(m, n) = \sum_k \sum_l h(m - k, n - l) u(k, l) + \eta(m, n),$$

Assim, temos que:

$$S_{vv}(\omega_1, \omega_2) = |H(\omega_1, \omega_2)|^2 S_{uu}(\omega_1, \omega_2) + S_{\eta\eta}(\omega_1, \omega_2)$$

$$S_{uv}(\omega_1, \omega_2) = H^*(\omega_1, \omega_2) S_{uu}(\omega_1, \omega_2) \text{ (Se } \eta \text{ é decorrelatado de } u \text{)}$$

$$G(\omega_1, \omega_2) = \frac{H^*(\omega_1, \omega_2) S_{uu}(\omega_1, \omega_2)}{|H(\omega_1, \omega_2)|^2 S_{uu}(\omega_1, \omega_2) + S_{\eta\eta}(\omega_1, \omega_2)} \Rightarrow \text{Filtro de Wiener}$$

O filtro é completamente determinado pela densidade espectral de potência do objeto (processo) e do ruído e da resposta em frequência do sistema de imagem;

$\Rightarrow$  O filtro de Wiener é em geral não separável;

## Filtro de Wiener para Imagens com Médias Não Nulas

Como  $\mu_v(m, n) = h(m, n) * \mu_u(m, n) + \mu_\eta(m, n)$ ,

Se  $\bar{x}(m, n) = x(m, n) - \mu_x(m, n)$ ,

$\Rightarrow \bar{v}(m, n) = h(m, n) * \bar{u}(m, n) + \bar{\eta}(m, n) \Rightarrow$  Posso aplicar o filtro de Wiener nas imagens sem média

$\Rightarrow$  Posso estimar  $\mu(m, n)$  fazendo médias locais.

$\Rightarrow$  Se  $\mu_u$  e  $\mu_\eta$  são constantes, só uma constante é adicionada à imagem processada.

**Fase:**

$$G = \frac{H^* S_{uu}}{|H|^2 S_{uu} + S_{\eta\eta}} \Rightarrow \angle G = -\angle H = \angle \frac{1}{H}$$

$\Rightarrow$  A fase do filtro de Wiener é igual à fase do filtro inverso;

$\Rightarrow$  O filtro de Wiener não compensa distorções de fase causadas pelo ruído.


## Filtro de Wiener para Ruído

Sem embaçamento:  $H = 1 \Rightarrow G = \frac{S_{uu}}{|H|^2 S_{uu} + S_{\eta\eta}} = \frac{SNR}{SNR + 1}$

$\Rightarrow SNR$  grande  $\Rightarrow G \approx 1$  (não preciso atenuar o sinal)

$\Rightarrow SNR$  pequeno  $\Rightarrow G \approx SNR$  (Atenuo o sinal de acordo com a sua relação sinal ruído: quanto mais ruído, mais atenuo)

$\Rightarrow$  Para imagens naturais,  $SNR$  tende a ser grande em baixas frequências e pequeno em altas frequências: o filtro de Wiener se comporta como um passa-baixas;




## Relação com filtragem inversa

$$\text{Se } S_{\eta\eta} = 0 \Rightarrow G = \frac{S_{uu}}{|H|^2 S_{uu} + S_{\eta\eta}} = \frac{H^* S_{uu}}{|H|^2 S_{uu}} = \frac{1}{H} \Rightarrow \text{é igual ao filtro inverso.}$$

$$\lim_{S_{\eta\eta} \rightarrow 0} G = \lim_{S_{\eta\eta} \rightarrow 0} \frac{H^* S_{uu}}{|H|^2 S_{uu} + S_{\eta\eta}} = \begin{cases} \frac{1}{H}, & H \neq 0 \\ 0, & H = 0 \end{cases} \Rightarrow \boxed{\text{Filtro Pseudo-Inverso}}$$

## Resposta em frequência do filtro de Wiener





# Exemplo:

Imagem borrada



Imagem borrada com ruído



Imagem restaurada pelo filtro pseudo-inverso



Imagem restaurada pelo filtro de Wiener



## PSDs desconhecidas

E se não conheço  $S_{\eta\eta}$  e  $S_{uu}$ ?








$\Rightarrow$  Faço  $\frac{S_{\eta\eta}}{S_{uu}} = K$ :

$$\Rightarrow G = \frac{H^* S_{uu}}{|H|^2 S_{uu} + S_{\eta\eta}} = \frac{H^*}{|H|^2 + \frac{S_{\eta\eta}}{S_{uu}}} = \frac{H^*}{|H|^2 + K}$$


$\Rightarrow K$  pode ser determinado manualmente;

## Exemplo

( $K$  escolhido manualmente para melhores resultados)




## Exemplo: Detecção de placas (pré-processamento)




$f(x,y)$



$h(x,y)$



$\hat{f}(x,y)$



blur = 30 pixels

## Filtragem de Wiener FIR

A equação do filtro de Wiener é:

$$G(\omega_1, \omega_2) = \frac{H^*(\omega_1, \omega_2) S_{uu}(\omega_1, \omega_2)}{|H(\omega_1, \omega_2)|^2 S_{uu}(\omega_1, \omega_2) + S_{\eta\eta}(\omega_1, \omega_2)} \Rightarrow g(n_1, n_2) \text{ é em geral IIR.}$$

⇒ Entretanto, sua resposta efetiva tem, em geral, tamanho bem menor que a imagem;

⇒ Filtros FIR ótimos podem aproximar o desempenho do filtro de Wiener;

⇒ O filtro de Wiener é implementado como um filtro de resposta ao impulso  $g(m, n)$  que minimiza o erro quadrático:

$$\hat{u}(m, n) = \sum_{i,j \in W} g(i, j) v(m - i, n - j), \quad W = -M \leq i, j \leq M$$

Da expressão do filtro de Wiener temos que:

$$\Rightarrow G | H |^2 S_{uu} + GS_{\eta\eta} = HS_{uu} \Rightarrow \text{seja } a(k, l) = (h \star h)(k, l)$$

$$\Rightarrow [g * a * r_{uu} + g * r_{\eta\eta}](k, l) = h * r_{uu}(k, l)$$

$$\Rightarrow [a * r_{uu} + r_{\eta\eta}] * g(k, l) = h * r_{uu}(k, l)$$

$\Rightarrow$  Se  $g$  é FIR com  $(2M + 1) \times (2M + 1)$  coeficientes, resolvo o sistema acima com  $(2M + 1) \times (2M + 1)$  incógnitas (coeficientes de  $g$ ).

**Exemplo:** Supondo  $r_{\eta\eta}(k, l) = \sigma_n^2 \delta(k, l)$  (ruído branco)

Definindo  $r_{uu}(k, l) = \sigma^2 r_0(k, l)$

$$\Rightarrow [(a * \sigma^2 r_0)(k, l) + \sigma_n^2 \delta(k, l)] * g(k, l) = h * (\sigma^2 r_0)(k, l)$$

$$\Rightarrow \left[ \frac{\sigma_\eta^2}{\sigma^2} \delta(k, l) + r_0(k, l) * a(k, l) \right] * g(k, l) = h(k, l) * r_0(k, l)$$

Empilhando as linhas e as colunas

$$\underbrace{\left[ \frac{\sigma_\eta^2}{\sigma^2} \mathbf{I} + \mathbf{R} \right]}_{\text{"truncado" para } (2M+1)^2(2M+1)^2} \underbrace{\mathbf{g}}_{(2M+1)^2 \text{ coefs}} = r_{uv} \Rightarrow \text{"truncado" para } (2M+1)^2 \text{ amostras.}$$

Sem embaçamento:  $H = 1 \Rightarrow h(k, l) = \delta(k, l) = a(k, l) \Rightarrow$  filtro FIR ótimo de ruído.

O tamanho do filtro FIR cresce com a quantidade de embaçamento e com o ruído.

$$\text{Sem embaçamento: } \left[ \frac{\sigma_\eta^2}{\sigma^2} \delta(k, l) + r_0(k, l) \right] * g(k, l) = r_0(k, l)$$



$SNR \rightarrow \infty \Rightarrow g(k, l) = \delta(k, l) \Rightarrow g$  possui 1 pixel.

$SNR \rightarrow 0 \Rightarrow \sigma_{\eta}^2 g(k, l) = r_0(k, l) \Rightarrow g$  possui tantas amostras quanto a região de suporte de  $r_0(k, l)$

$\Rightarrow$  Se  $r_0(k, l) = 0.95^{\sqrt{k^2+l^2}} \Rightarrow g$  de tamanho 32 é suficiente.

## Filtros FIR Variantes com o Deslocamento

Filtragem de imagens com embaçamento variantes no deslocamento:

⇒ Um bom modelo é assumir média e variâncias não-estacionárias e autocovariâncias estacionárias, isto é:

$$\begin{cases} E[u(m, n)] = \mu(m, n) \\ E\{[u(m, n) - \mu(m, n)][u(m - k, n - l) - \mu(m - k, n - l)]\} = \sigma^2(m, n)r_0(k, l) \end{cases}$$

Supondo que a PSF possui região de suporte contida em  $W$  e  $h, \mu$  e  $\sigma^2$  variam lentamente:

$$\Rightarrow \hat{u}(m, n) = \sum_{(i,j) \in W} \tilde{g}_{m,n}(i, j) v(m - i, n - j)$$

$$\tilde{g}_{m,n}(i, j) = g_{m,n}(i, j) + \frac{1}{(2M+1)^2} \left[ 1 - \sum_{(k,l) \in W} g_{m,n}(k, l) \right]$$

$$g_{m,n}(i, j) \text{ é a solução da equação } \left[ \frac{\sigma_\eta^2}{\sigma_{m,n}^2} \mathbf{I} + \mathbf{R} \right] \mathbf{g} = \mathbf{r}_{uv}, \text{ com } \sigma_{m,n}^2 \text{ estimado da observação.}$$

## Outros Filtros no Domínio da Frequência

- Filtro de média geométrica:

$$G_s = (H^-)^s \left( \frac{S_{uu}H^*}{S_{uu} |H|^2 + S_{\eta\eta}} \right)^{1-s}, \quad 0 \leq s \leq 1, \quad H^- = \text{filtro pseudo-inverso.}$$

$\Rightarrow$  se  $s = \frac{1}{2} \Rightarrow$  PSD da saída = PSD do objeto.